Факультет компьютерных наук | Машинное обучение | Москва 2026

# Лекция 7.1.
# Полиномиальная регрессия и регуляризация

Преподаватель: Меликян Алиса Валерьевна, amelikyan@hse.ru
кандидат наук, доцент Департамента программной инженерии ФКН НИУ ВШЭ,
академический руководитель магистерской программы
«Искусственный интеллект и продуктовый подход в HR-менеджменте»

# Полиномиальная регрессия

Полиномиальная регрессия – это расширение линейной регрессии, позволяющее моделировать нелинейные зависимости между признаками и целевой переменной за счёт добавления полиномиальных признаков (например, $x^2, x^3$ и т.д.). Несмотря на то что модель остаётся линейной по параметрам, она способна аппроксимировать сложные кривые и выявлять более гибкие закономерности в данных. Однако с увеличением степени полинома резко возрастает риск переобучения: модель начинает подстраиваться под шум, теряя способность к обобщению на новых данных. Именно поэтому на практике полиномиальная регрессия часто используется в сочетании с методами регуляризации, которые помогают найти баланс между точностью и устойчивостью, контролируя сложность модели.

# Нелинейные зависимости

Один из вариантов моделирования нелинейной зависимости – бинаризация числовых признаков, то есть разбиение числовой переменной на интервалы и замена её набором фиктивных (dummy) переменных. Но при этом теряется информация о порядке внутри интервала, а при большом числе интервалов растет размерность модели.

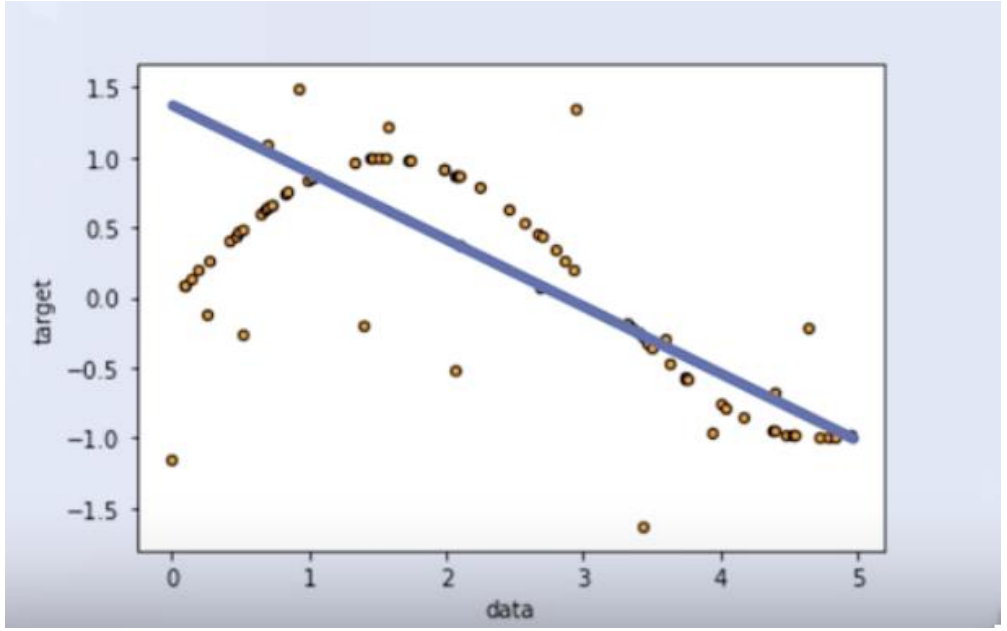


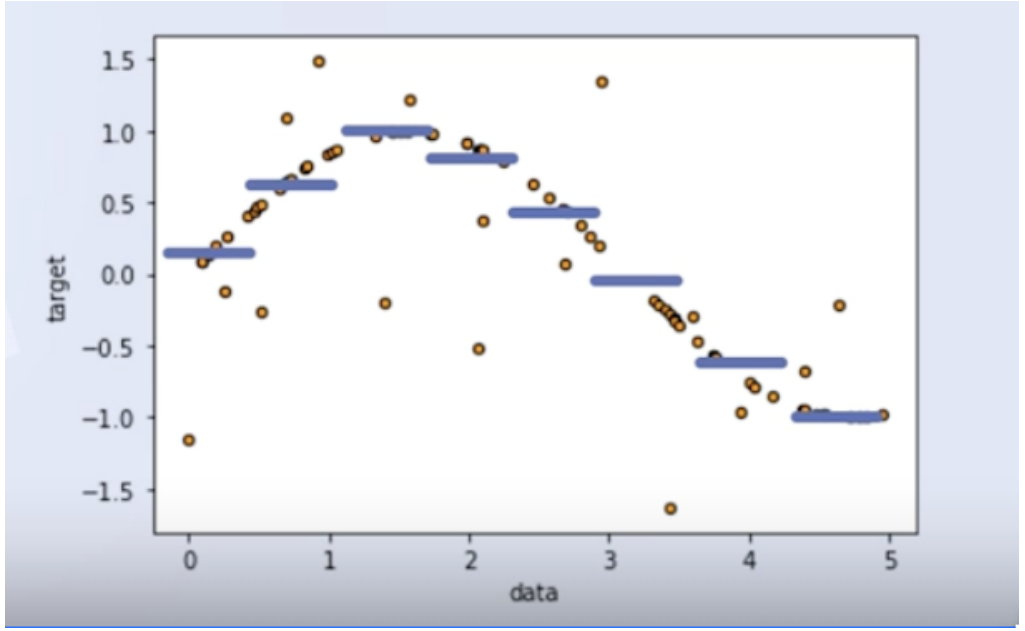

# Полиномиальная модель

Полиномиальная модель использует многочлены степени $n$, чтобы аппроксимировать нелинейные зависимости без явного задания формы функции. Может быть записана как:

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \cdots + \beta_n x^n + \varepsilon$$

$\beta_0, \beta_1, \ldots, \beta_n$ – коэффициенты модели, которые нужно оценить,

$n$ – степень полинома (чем выше, тем гибче модель, но выше риск переобучения),

$\varepsilon$ – случайная ошибка или шум.

# Особенности полиномиальной модели

Полиномиальная регрессия хорошо описывает данные внутри диапазона наблюдений, но при выходе за его пределы (экстраполяции) часто начинает вести себя нестабильно. Предсказания могут стремительно уходить в плюс или минус бесконечность. Это происходит потому что полином подстраивается под данные, а не под специфику взаимосвязи. Не всегда способен отразить физический или экономический смысл задачи.

Если полиномиальная регрессия недостаточно гибкая, можно использовать нелинейные регрессионные модели, где функция заранее задается: логистическая, экспоненциальная, степенная, логарифмическая и пр.

# Полиномиальная регрессия в HR

Производительность сотрудника и стаж (U-образная зависимость)

Связь между стажем (tenure) и производительностью часто нелинейная:

- первые месяцы → рост (адаптация)
- 2–4 года → пик
- затем возможен спад (выгорание, рутина)

$$Performance = a + b_1 Tenure + b_2 Tenure^2$$

Если коэффициент $b_2$ при $Tenure^2$ отрицательный – получаем перевёрнутую U-образную кривую. На основе модели можно определить момент пика эффективности, планировать карьерные треки, вовремя запускать ротацию или развитие.

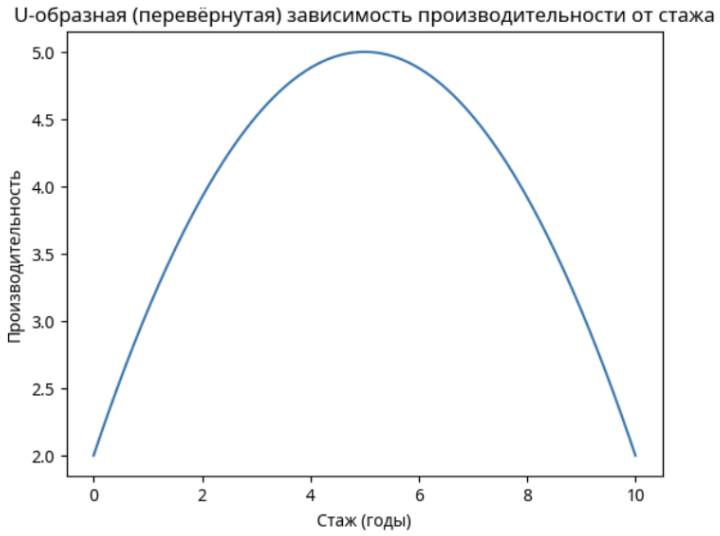

# Полиномиальная регрессия в HR

Возможна замедляющаяся отдача от стажа (убывающая предельная отдача).

- первые годы → производительность растёт быстро (обучение, рост навыков)
- средний стаж → рост продолжается, но медленнее
- большой стаж → производительность всё ещё растёт, но каждый дополнительный год даёт меньший прирост

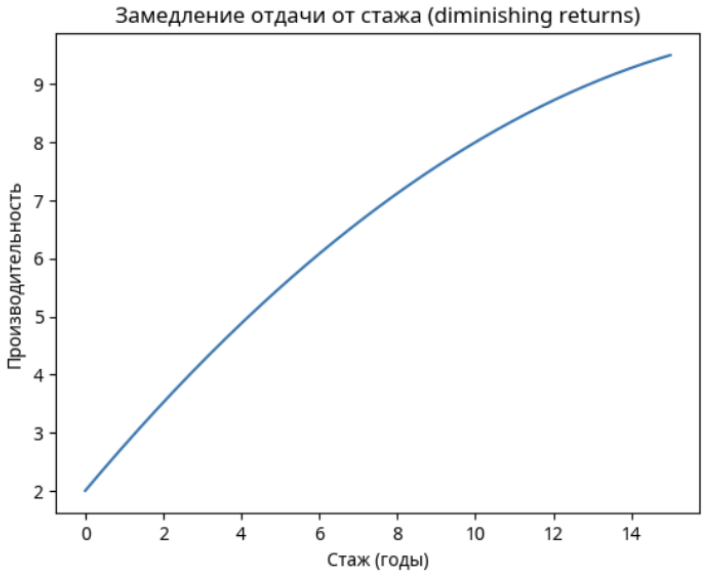


$$Performance = a + b_1 Tenure + b_2 Tenure^2$$

$b_1 > 0, \quad b_2 < 0$ (маленький по модулю)

Кривая вогнутая, но не падает в наблюдаемом диапазоне.

Опыт всегда помогает, но каждый следующий год даёт меньше прироста производительности.

# Полиномиальная модель

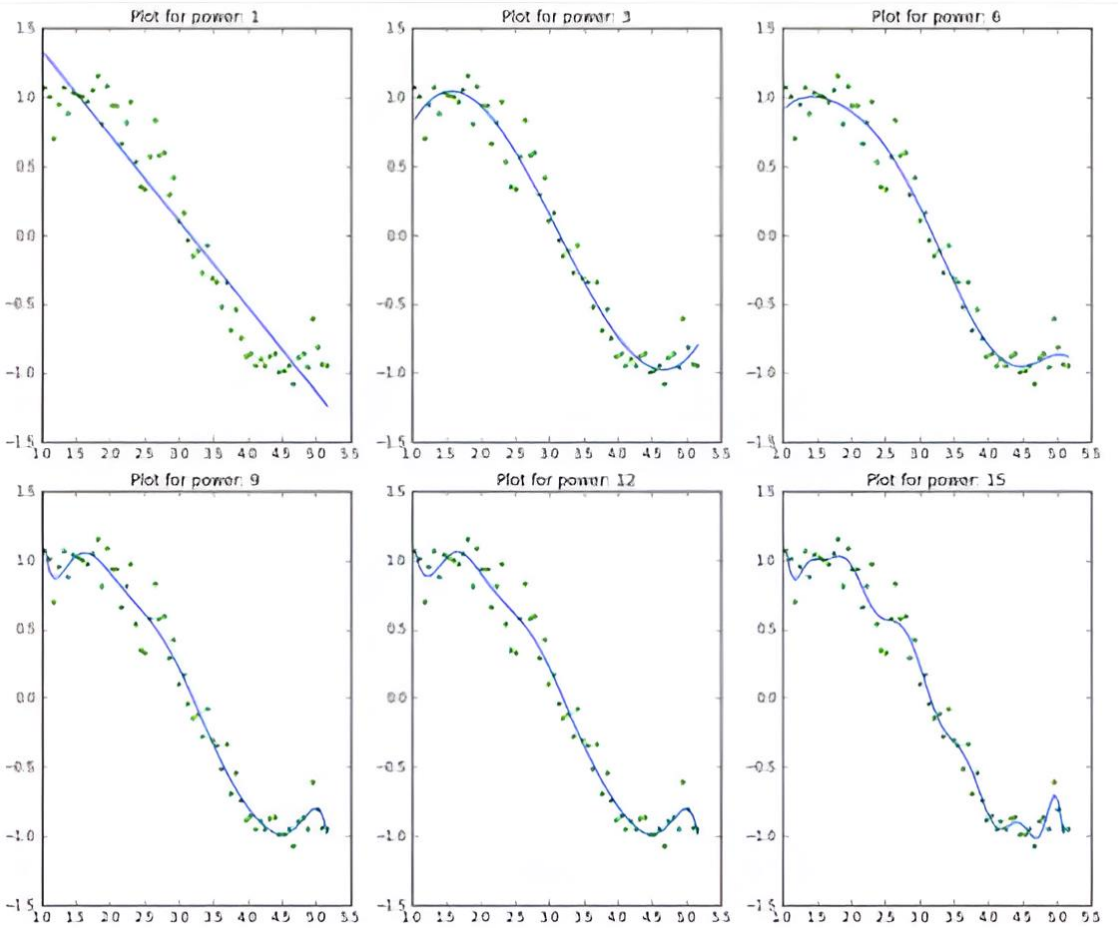

# Полиномиальная модель

$$a(x) = w_0 + w_1 x$$

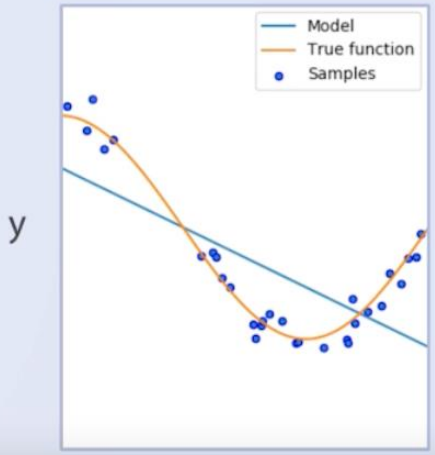


$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4$$

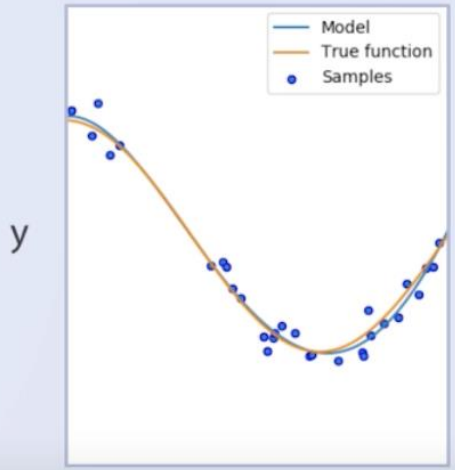


$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \cdots + w_{15} x^{15}$$

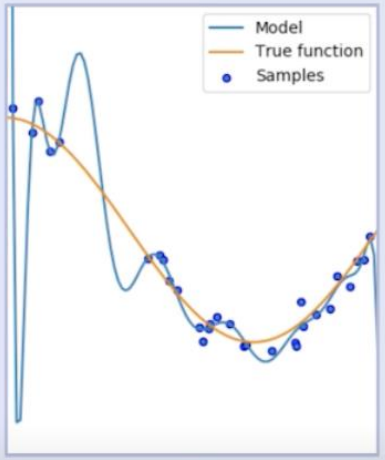


**Переобучение**

# Полиномиальная модель: ограничения

- **Переобучение** – если степень полинома высокая модель может подгоняться под данные. Чем выше степень – тем выше риск переобучения.
- **Плохая экстраполяция** – за пределами обучающего диапазона старшие степени быстро растут, предсказания становятся нереалистичными.
- **Мультиколлинеарность** – признаки сильно коррелированы между собой, что приводит к нестабильности коэффициентов.
- **Сложность интерпретации** – коэффициенты трудно интерпретировать.
- **Чувствительность к выбросам** – если выброс находится на краю диапазона, то полином «изгибается» под него.
- **Проблема выбора степени** - обычно подбирается через кросс-валидацию.

# Регуляризация в линейной регрессии

Регуляризация в линейной регрессии – это метод уменьшения переобучения (overfitting) модели путём добавления штрафа за слишком большие коэффициенты.

Обычная линейная регрессия минимизирует только ошибку, а регуляризация добавляет штраф за сложность модели. Это позволяет предотвратить переобучение, чтобы модель не запоминала шум, а лучше обобщала данные.

Регуляризация особенно нужна когда мало данных, много признаков, и наблюдается мультиколлинеарность. Признаки нужно масштабировать перед регуляризацией.

# Регуляризация

Наиболее распространённые методы регуляризации в линейных моделях:

- Ridge-регуляризация;
- Lasso-регуляризация;
- Elastic Net.

Функция потерь:

$$Min_{w,b}\,(MSE + penalty) = Min\left[\frac{1}{N}\sum_{i=1}^{N}\left(y_i - f_{w,b}(X_i)\right)^2 + penalty(w)\right]$$

# Ridge-регуляризация (гребневая)

L2-регуляризация (Ridge) добавляется штраф за квадраты коэффициентов, то есть штрафуются высокие коэффициенты.

Функция потерь:

$$\frac{1}{n}\sum(y_i - \hat{y}_i)^2 + \lambda\sum w_j^2$$

$\lambda$ – коэффициент регуляризации

чем больше $\lambda$, тем сильнее штраф

После регуляризации коэффициенты уменьшаются, но никогда не становятся ровными нулю. Ridge не осуществляет отбор признаков.

Используется когда все признаки полезны, но есть мультиколлинеарность.

# Ridge-регуляризация

As $\lambda$ increases, the model becomes simpler

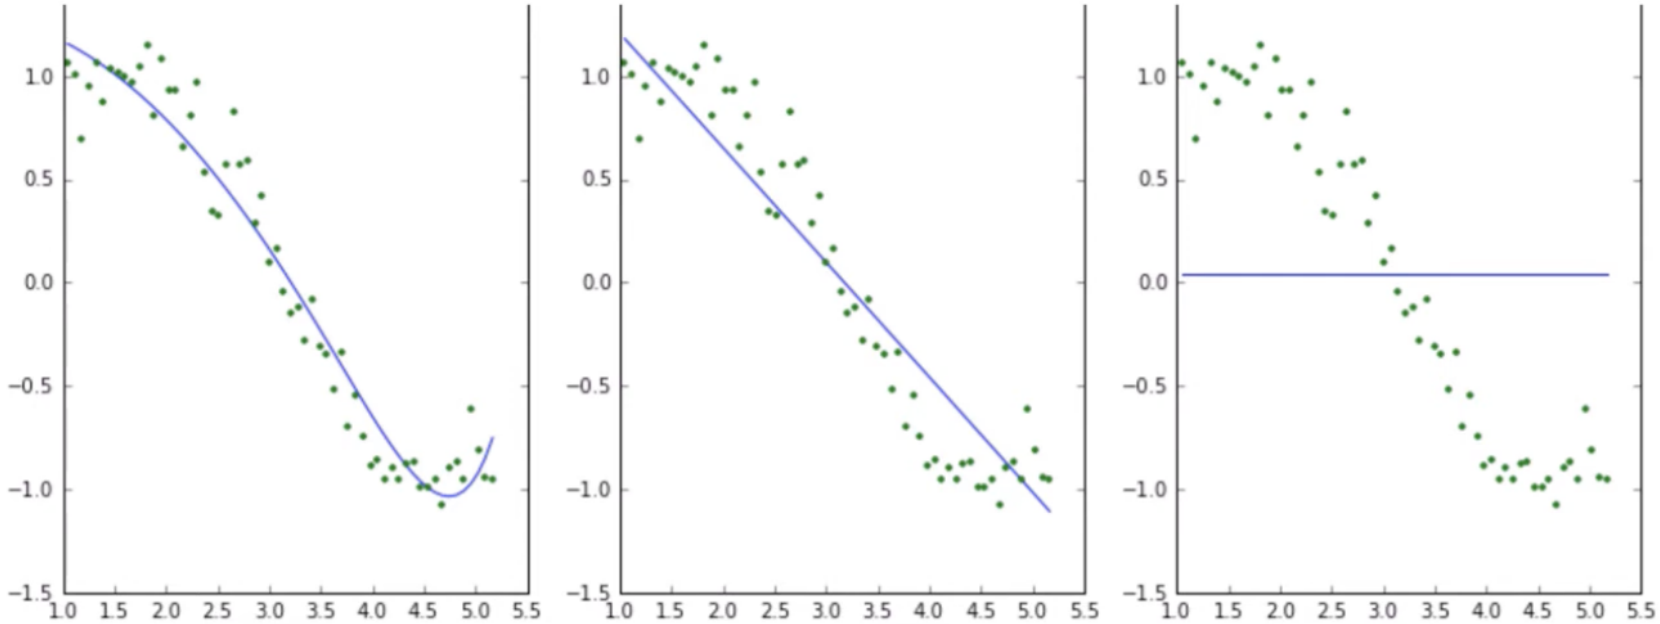

# Ridge-регуляризация

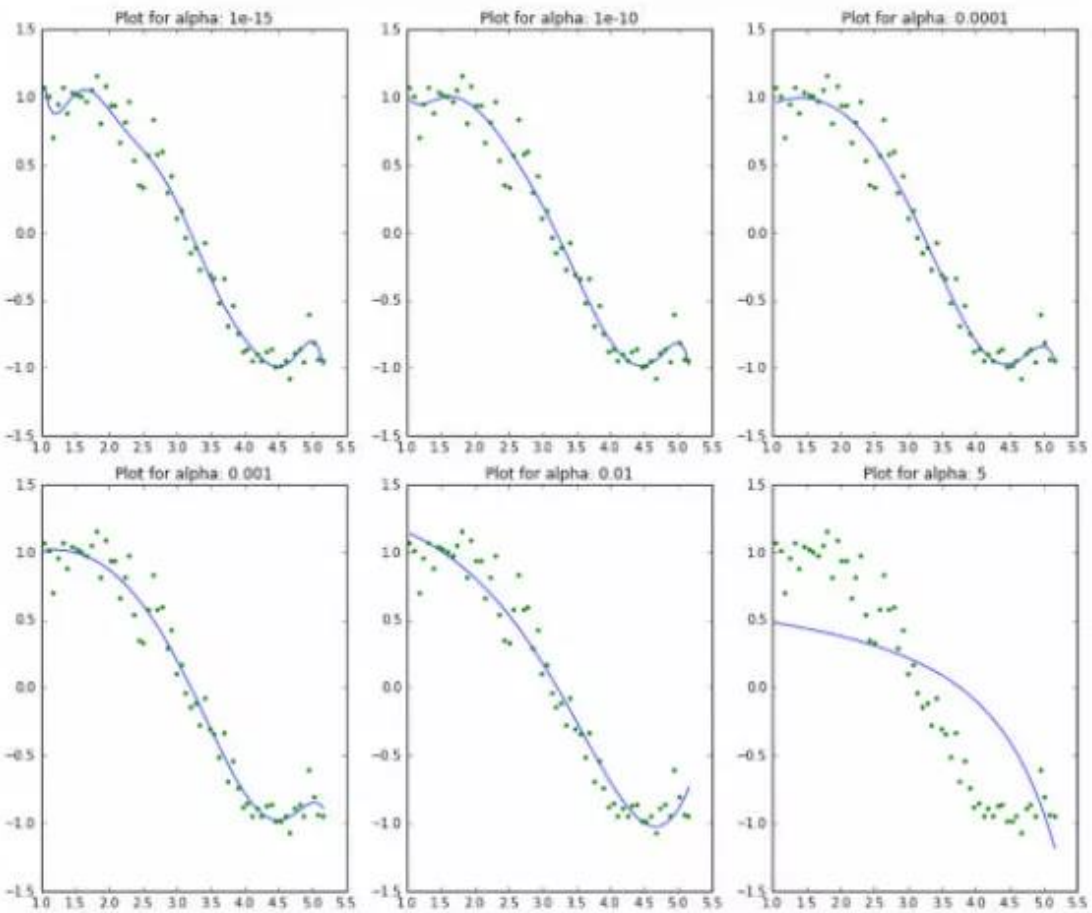

# Ridge-регуляризация

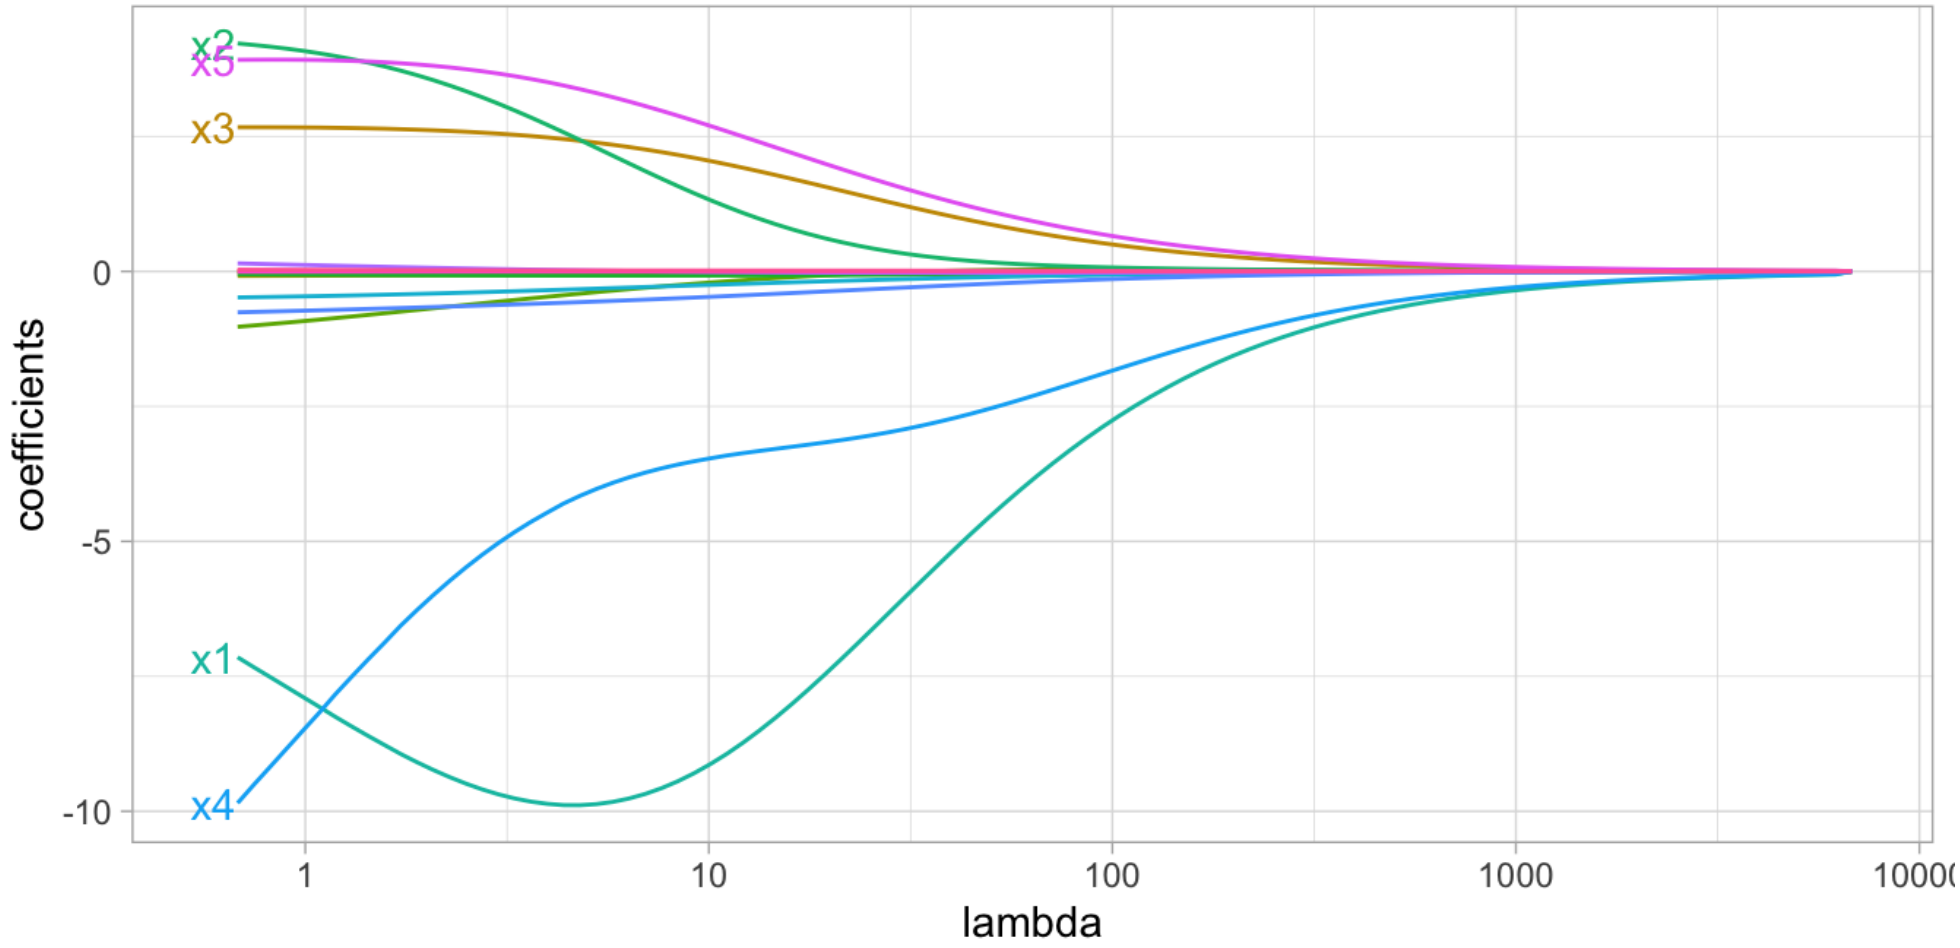

# Ridge-регуляризация

Оптимизация ищет точку минимума ошибки, но решение должно лежать внутри круга ограничений. То есть круг определяет допустимую область значения коэффициентов. Поскольку у круга гладкая граница коэффициенты уменьшаются, но почти никогда не становятся ровно нулём, то есть отбора признаков не происходит.

Когда мы ищем компромисс между ошибкой и ограничением, мы чаще всего касаемся круга не в углу. В результате оба веса $\beta_1$ и $\beta_2$ становятся маленькими, но не нулевыми.

$\beta_1^2 + \beta_2^2 \leq t$, радиус круга = $\sqrt{t}$

$\lambda \uparrow$(сильнее регуляризация) $\rightarrow t \downarrow \rightarrow$ радиус уменьшается

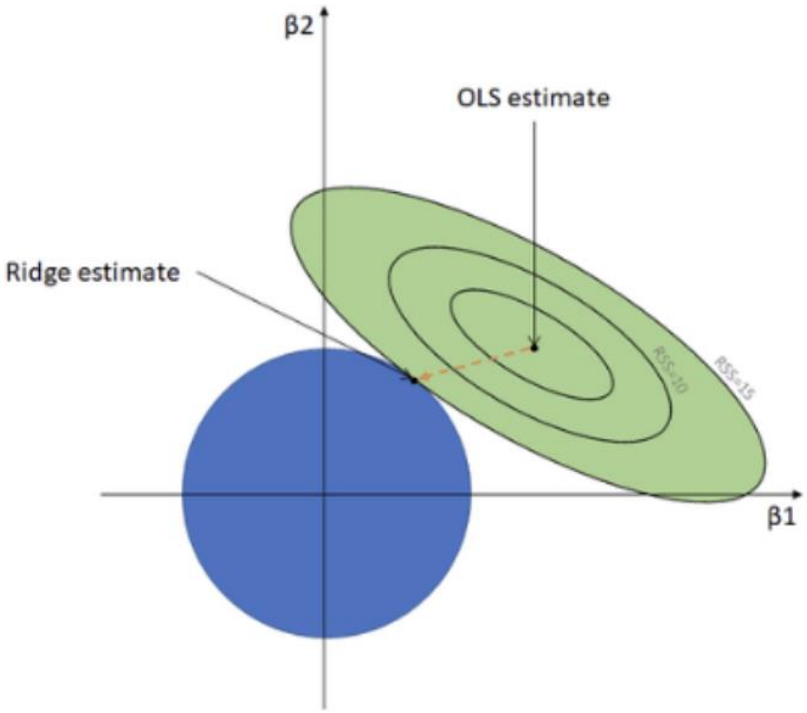

# Lasso-регуляризация (Least Absolute Shrinkage and Selection Operator)

L1-регуляризация (Lasso) добавляется штраф за модуль коэффициентов.

$$\frac{1}{n}\sum(y_i - \hat{y}_i)^2 + \lambda \sum |w_j|$$

Происходит отбор признаков. Некоторые коэффициенты становятся равными нулю. Используется когда признаков много и нужно выбрать самые важные.

Может снижать влияние мультиколлинеарности, выполняя отбор признаков и обнуляя коэффициенты некоторых коррелирующих признаков.

# Lasso-регуляризация

Оптимизация ищет точку минимума ошибки, но решение должно лежать внутри ромба ограничений. Когда мы ищем компромисс между ошибкой и ограничением, мы чаще всего касаемся ромба именно в углу. В результате один из весов $\beta_1$ или $\beta_2$ может стать нулевым.

$$|\beta_1| + |\beta_2| \leq t$$

Результат: модель сама выбрасывает ненужные признаки.

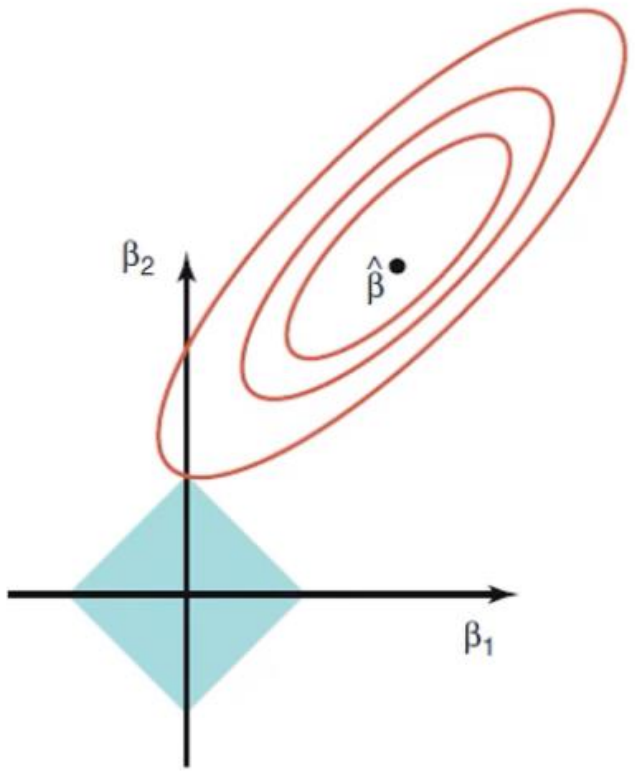

# Lasso-регуляризация

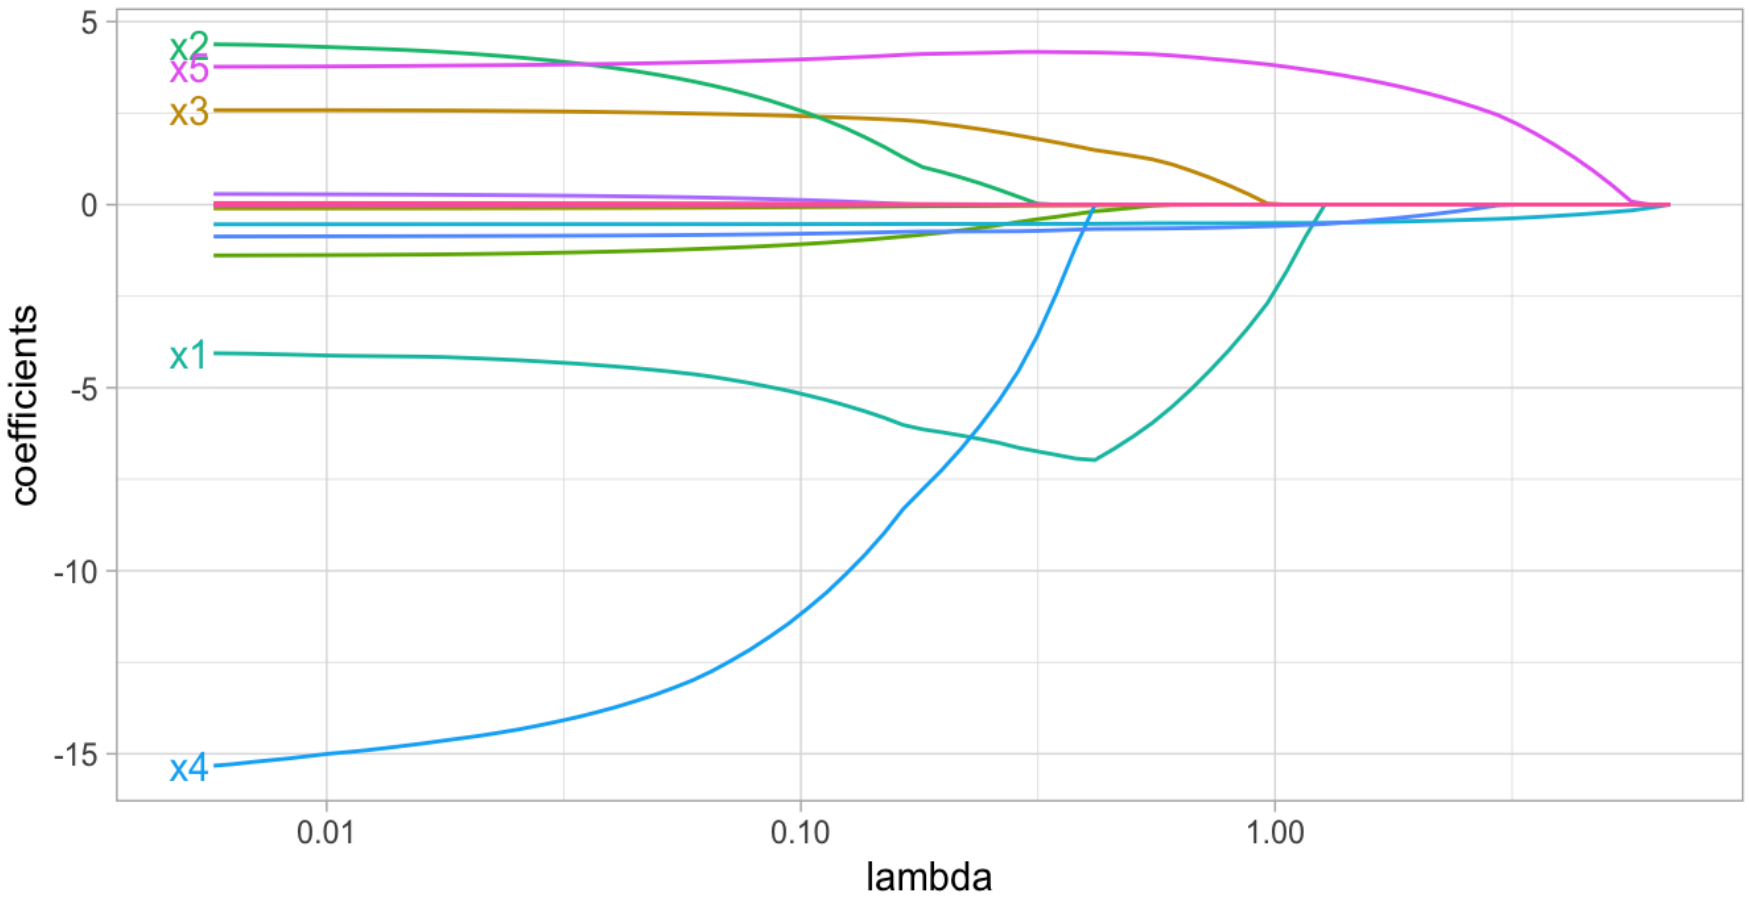

# Lasso-регуляризация

$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \dots + w_{15} x^{15}$$

$$\frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2 \to \min_w$$

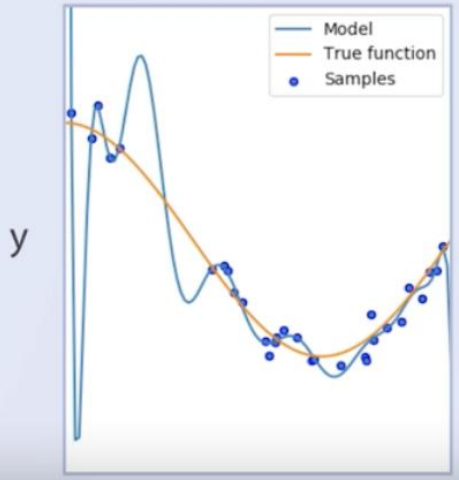


$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \dots + w_{15} x^{15}$$

$$\frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2 + 0.01\,\|w\|^2 \to \min_w$$

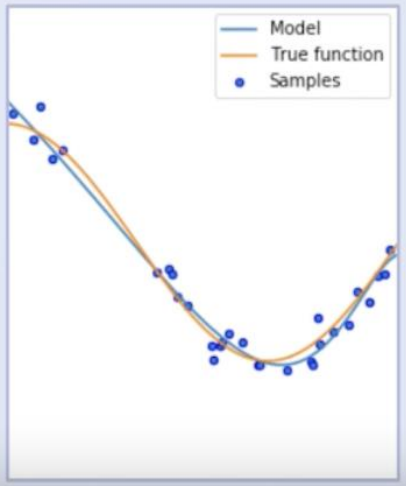

# Lasso-регуляризация

$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \dots + w_{15} x^{15}$$

$$\frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2 + 1\,\|w\|^2 \to \min_w$$

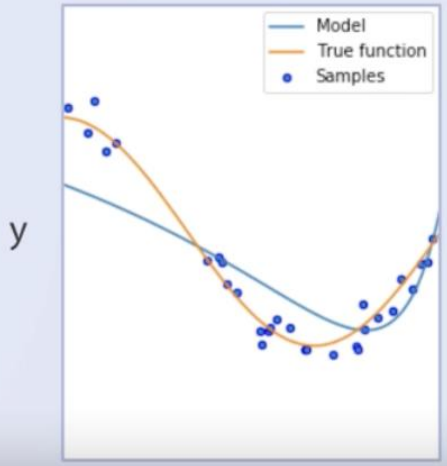


$$a(x) = w_0 + w_1 x + w_2 x^2 + w_3 x^3 + w_4 x^4 + \dots + w_{15} x^{15}$$

$$\frac{1}{\ell}\sum_{i=1}^{\ell}(a(x_i) - y_i)^2 + 100\,\|w\|^2 \to \min_w$$

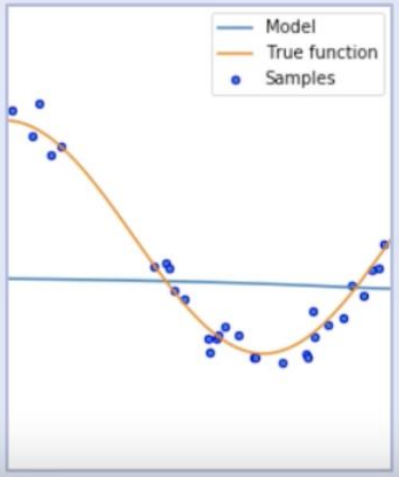

# Rigde или Lasso?

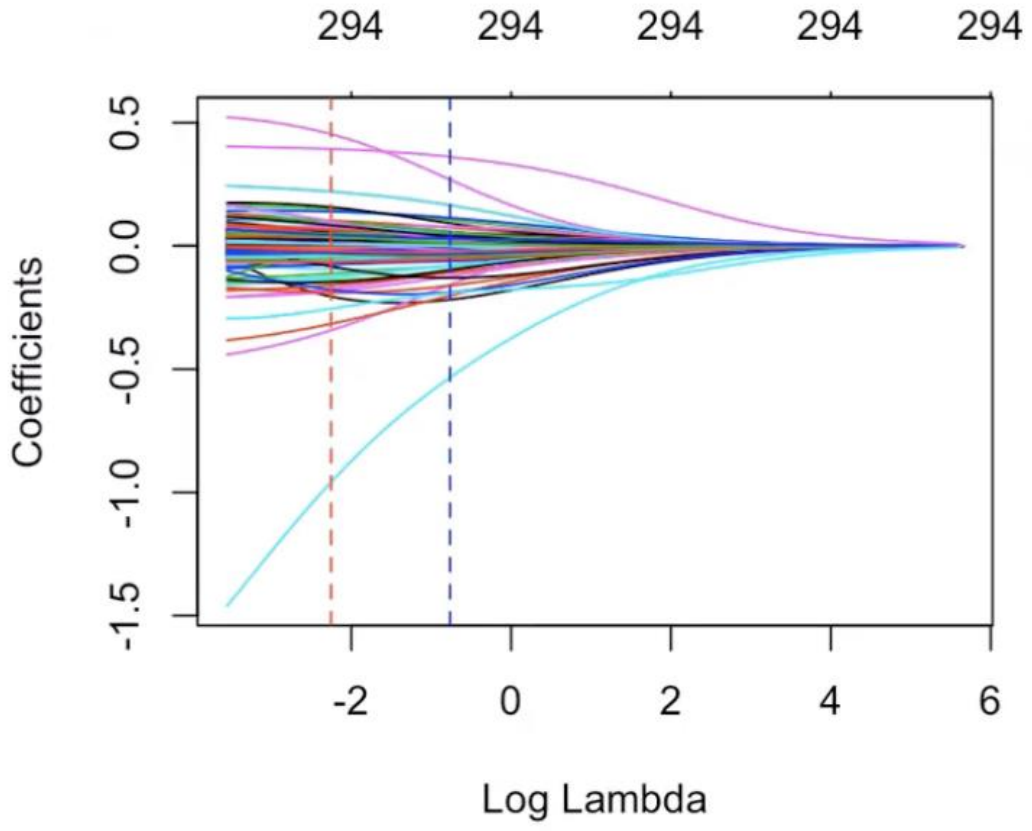


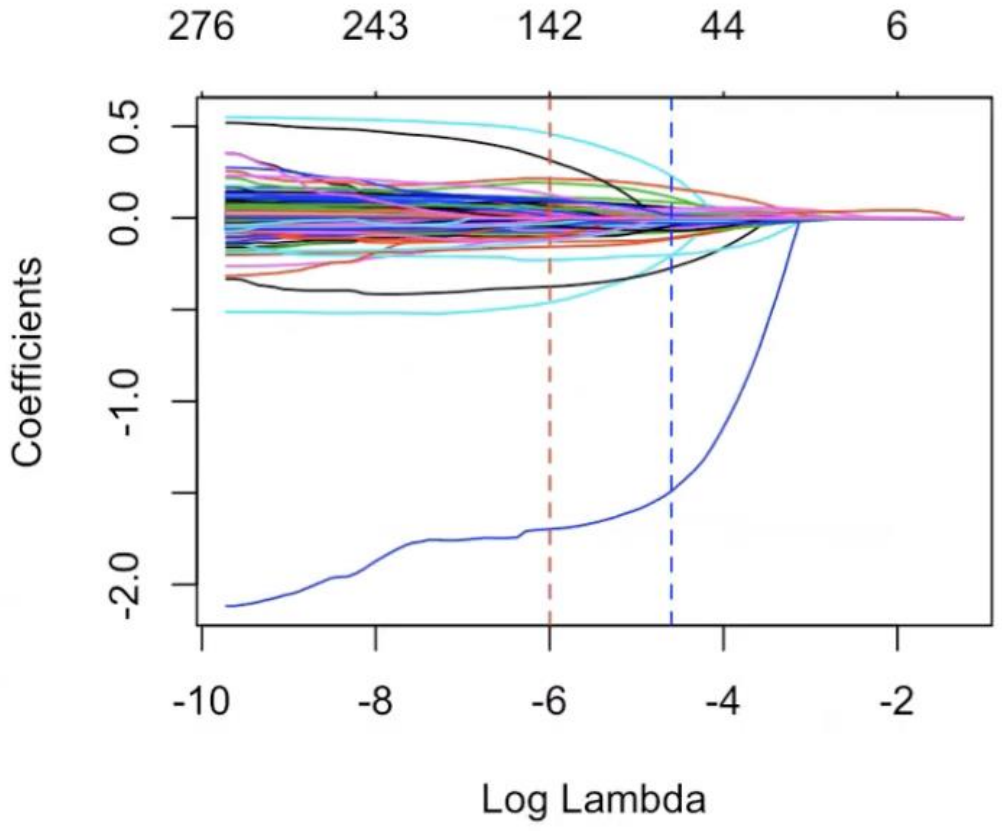

# Elastic Net

Комбинация L1 и L2. Функция потерь:

$$\frac{1}{n}\sum(y_i - \hat{y}_i)^2 + \lambda_1 \sum |w_j| + \lambda_2 \sum w_j^2$$

Сочетает оба подхода и используется когда много признаков и они коррелируют.

Осуществляет отбор признаков, при этом стабилизирует модель.

# Elastic Net

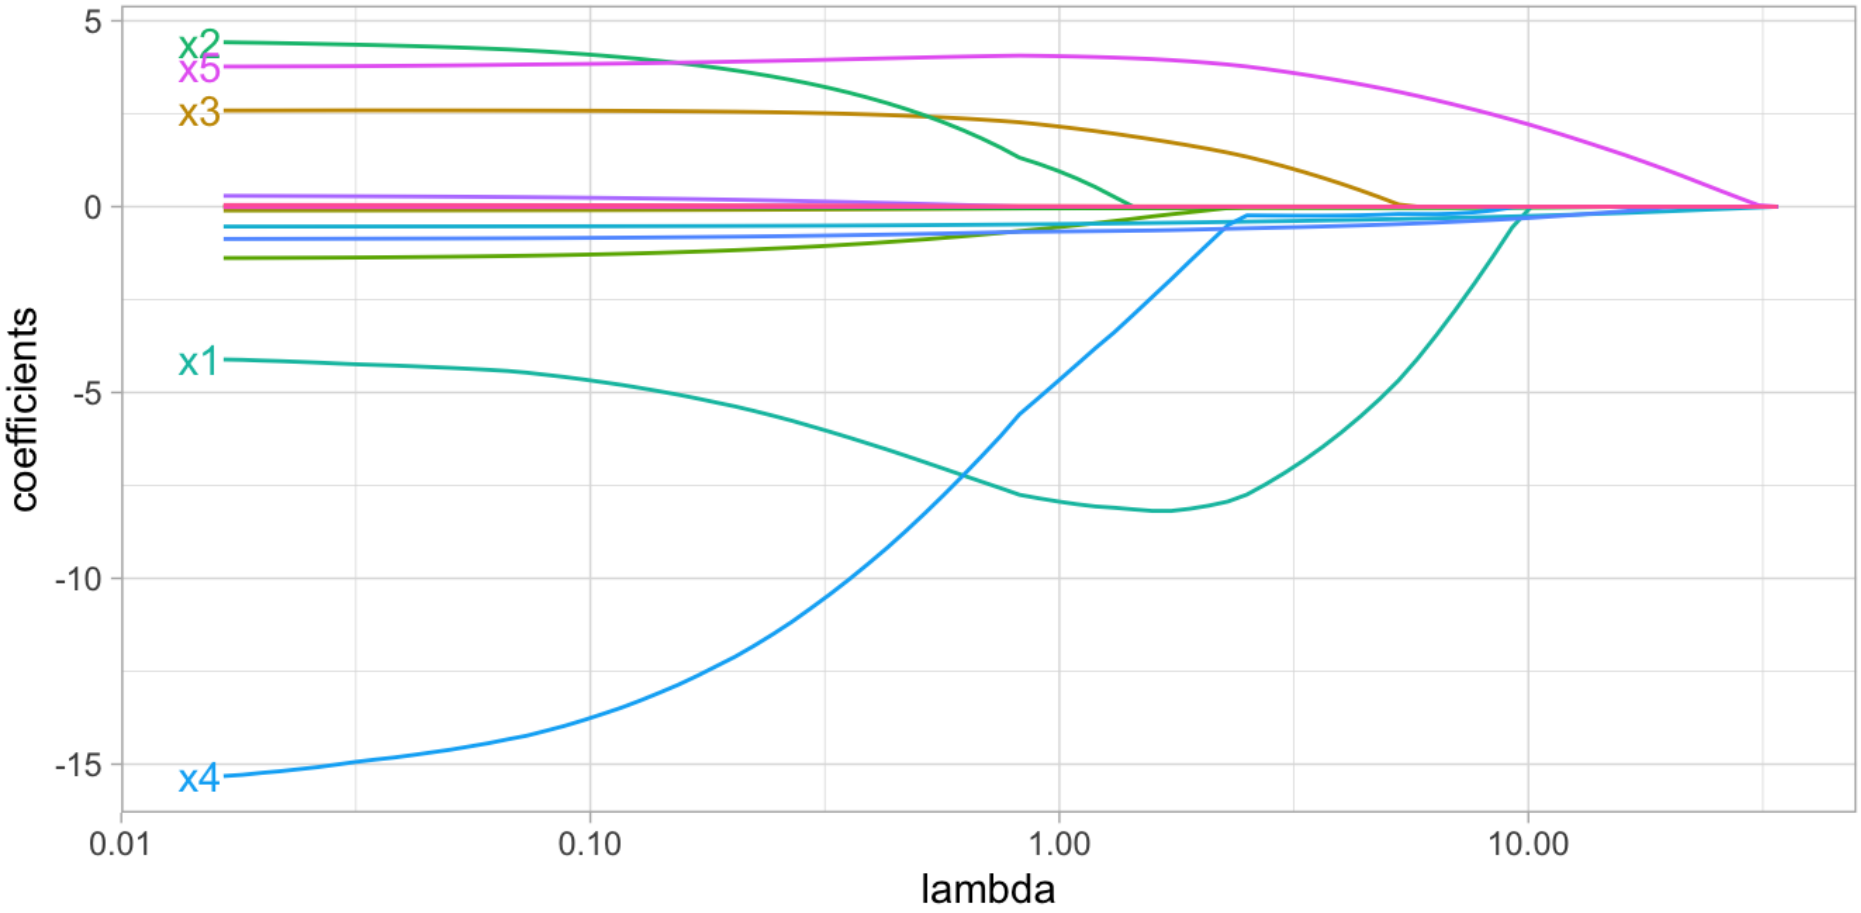

# Lambda ($\lambda$)

| λ | эффект |
|---|---|
| 0 | обычная линейная регрессия |
| маленькое | слабая регуляризация |
| большое | коэффициенты сильно уменьшаются |
| очень большое | модель почти константа |

Чем больше $\lambda$, тем сильнее штраф и тем меньше становятся веса.

- Если $\lambda$ слишком мало, регуляризация почти не влияет, и риск переобучения сохраняется.
- Если $\lambda$ слишком велико, модель чрезмерно упрощается и возникает недообучение.

Оптимальное значение подбирается через кросс-валидацию.

# Регуляризация

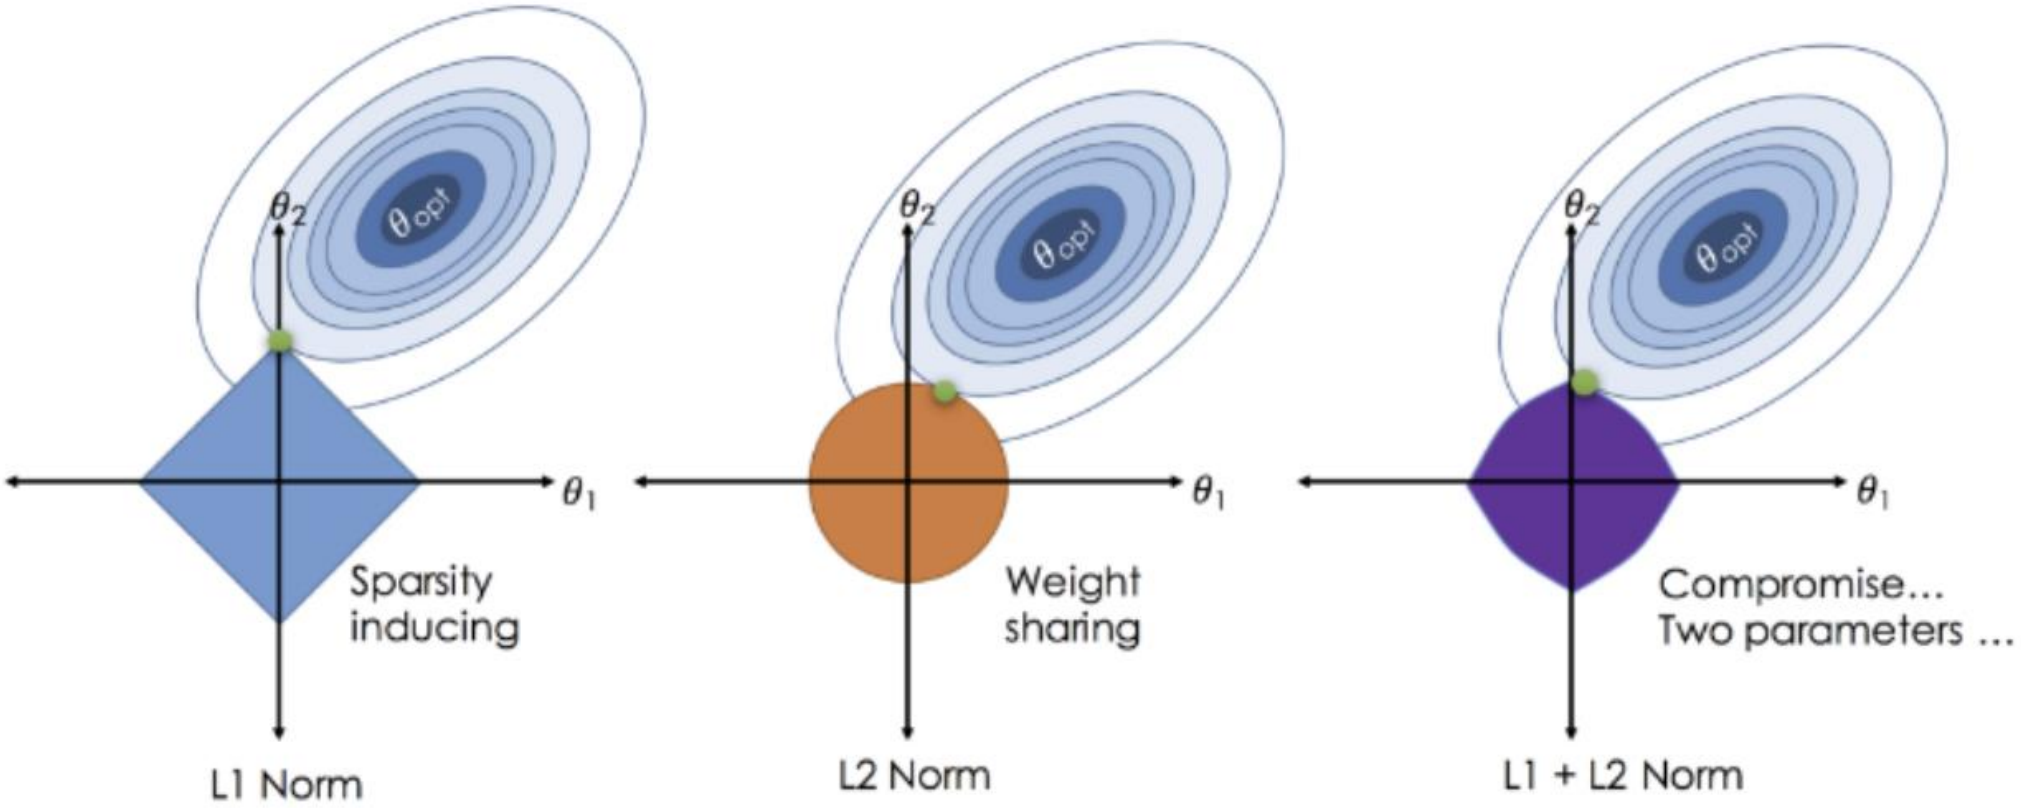

# Этапы проведения регуляризации

1. Подготовка данных: one-hot кодирование и масштабирование признаков.
2. Кросс-валидация для подбора параметров регуляризации.
3. Построение модели с регуляризацией.
4. Интерпретация коэффициентов.

# Регуляризация не всегда нужна

Регуляризация в линейных моделях не всегда необходима. Есть несколько ситуаций, когда она почти ничего не меняет:

- нет мультиколлинеарности;
- малое число признаков;
- большая выборка;
- признаки уже хорошо отобраны.

# Регуляризация в HR-моделях

Проблемы HR-данных:

- Много коррелированных признаков;
- Шумы;
- Много категориальных признаков (после one-hot получается много столбцов).

На практике после регуляризации в HR-моделях остаются сильные факторы, модель перестает подстраиваться под шум и устраняется проблема мультиколлинеарности.

# Спасибо за внимание!