Факультет компьютерных наук | Машинное обучение | Москва 2026

Лекция 8.1.
Логистическая регрессия

Преподаватель: Меликян Алиса Валерьевна, amelikyan@hse.ru
кандидат наук, доцент Департамента программной инженерии ФКН НИУ ВШЭ,
академический руководитель магистерской программы
«Продуктовый подход и аналитика данных в HR-менеджменте»

Логистическая регрессия

Мультиномиальная и порядковая логистические регрессии представляют собой расширения классической бинарной логистической регрессии и позволяют моделировать зависимость категориальных переменных от набора предикторов.

Мультиномиальная логистическая регрессия применяется, когда целевая переменная имеет более двух категорий без естественного порядка.

Порядковая логистическая регрессия используется для категориальных переменных с упорядоченными уровнями, учитывая их иерархическую структуру, что позволяет эффективнее интерпретировать влияние предикторов на смещение между уровнями.

Логистическая регрессия

Модель	Целевая переменная	Независимые переменные
Бинарная	Бинарная (да/нет)	• Метрические • Бинарные • Категориальные, представленные набором бинарных переменных
Мультиномиальная	Номинальная, имеющая более двух не упорядоченных значений (красный, желтый, синий)	
Порядковая	Порядковая, имеющая более двух упорядоченных значений (плохо, хорошо, отлично)	

Мультиномиальная регрессия

Для обучения модели используются два основных подхода: One-vs-Rest и Softmax.

1) One-vs-Rest (OvR)

Строится несколько бинарных логистических регрессий для каждой категории против всех остальных. Каждая модель оптимизируется независимо, что приводит к отсутствию согласованной общей вероятностной модели для всех классов. На этапе предсказания выбирается класс с максимальным значением оцененной вероятности. Данный подход игнорирует взаимозависимости между классами и может давать некалиброванные вероятности. Возможны противоречивые оценки (несколько классов с высокой вероятностью).

One-vs-Rest

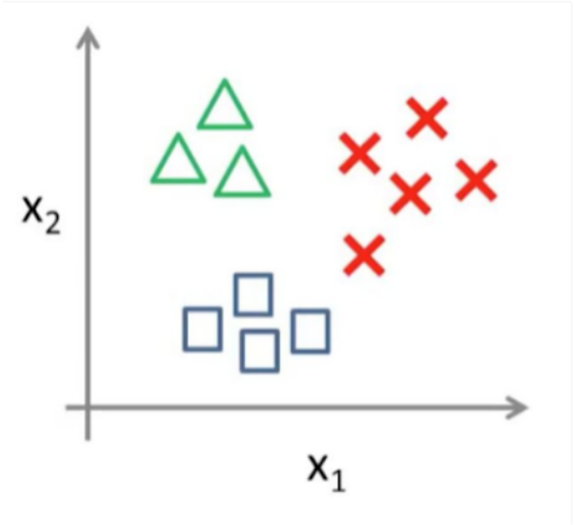

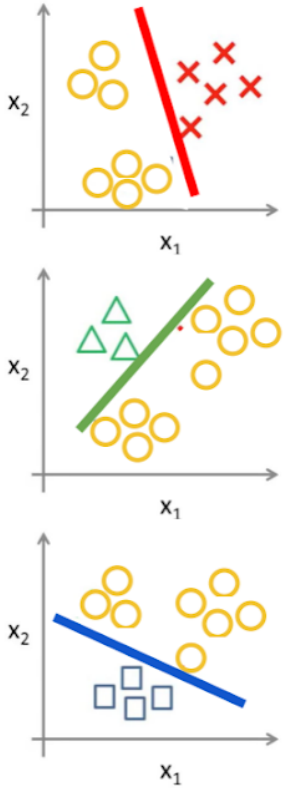

$$P(Y=0|x)$$

$$P(Y=1|x)$$

$$P(Y=2|x)$$

Predict the class with the highest probability

Мультиномиальная регрессия

2) Softmax (Multinomial Logistic Regression)

Мультиномиальная логистическая регрессия рассматривает задачу как единую модель, которая сразу оценивает вероятности всех классов. Параметры обучаются совместно на основе максимизации правдоподобия. В отличие от подхода One-vs-Rest, здесь вероятности корректно нормированы (в сумме дают единицу), а сама модель имеет ясную и последовательную вероятностную интерпретацию.

Усреднение метрик качества классификации по классам

В многоклассовой классификации метрики (Precision, Recall, F1) качества классификации могут быть усреднены разными способами :

- Macro-average: метрика считается отдельно для каждого класса, затем усредняется. Используется когда все классы одинаково важны.
- Micro-average: суммируются все TP, FP, FN по всем классам, потом считается метрика. В этом случае каждый объект имеет одинаковый вес. Рекомендуется использовать когда важна общая точность по всем объектам или когда классы сильно несбалансированы.
- Weighted-average: учитывается размер классов, но метрики считаются отдельно по классам (аналог macro-averaging, но с учетом частоты встречаемости каждого класса).

Усреднение метрик по классам

	precision	recall	f1-score	support
Aeroplane	0.67	0.67	0.67	3
Boat	0.25	1.00	0.40	1
Car	1.00	0.50	0.67	6
accuracy			0.60	10
macro avg	0.64	0.72	0.58	10
weighted avg	0.82	0.60	0.64	10

Per-Class F1 scores

Average F1 scores

Интерпретация коэффициентов мультиномиальной логистической регрессии (классическая версия из учебников и реализация в библиотеке statsmodels)

Каждый коэффициент показывает изменение логарифма отношения шансов выбора данной категории относительно базовой при увеличении предиктора на единицу, при условии, что все остальные признаки фиксированы. Положительное значение коэффициента указывает на увеличение шансов отнесения к рассматриваемой категории относительно базовой, а отрицательное – на снижение этих шансов.

Интерпретация коэффициентов мультиномиальной логистической регрессии с softmax в sklearn

В мультиномиальной логистической регрессии с softmax в sklearn каждый коэффициент показывает изменение линейного скоринга (logit) соответствующего класса при увеличении предиктора на единицу при фиксированных остальных признаках. Эти скоринги затем преобразуются в вероятности. Важно, что интерпретация идёт не относительно базового класса, а относительно изменения баланса между всеми классами. Положительное значение коэффициента увеличивает вклад признака в логит данного класса, а отрицательное – уменьшает его, перераспределяя вероятность в пользу других классов.

Такой подход является более гибким, поскольку позволяет напрямую сравнивать влияние предикторов на относительные предпочтения классов, а не ограничиваться интерпретацией только через одну референтную категорию.

Интерпретация коэффициентов мультиномиальной логистической регрессии

Predictor	Coef	SE Coef	Z	P	Odds Ratio
Logit 1: (Car/Walking)					
Constant	-37.9929	20.7069	-1.83	0.067	
Distance	1.69724	0.634966	2.67	0.008	5.46
Income	0.215653	0.182070	1.18	0.236	1.24
Logit 2: (Bus/Walking)					
Constant	2.12543	1.53808	1.38	0.167	
Distance	0.653565	0.254944	2.56	0.010	1.92
Income	-0.138963	0.0566681	-2.45	0.014	0.87
Logit 3: (Bike/Walking)					
Constant	-3.27498	3.36553	-0.97	0.331	
Distance	0.708729	0.272113	2.60	0.009	2.03
Income	-0.0736886	0.0648364	-1.14	0.256	0.93

- Расстояние (Distance) – ключевой фактор: чем дальше, тем выше шансы выбрать транспорт, а не ходьбу. Машина реагирует на расстояние сильнее всего (OR = 5.46), затем велосипед (2.03) и автобус (1.92).
- Доход (Income) влияет только на выбор автобуса вместо ходьбы: более высокий доход снижает вероятность выбора автобуса (OR 0.87).

Какой кофе выберут студенты?

Мультиномиальная логистическая регрессия используется для предсказания выбора напитка: ☕ Эспрессо (базовая категория), 🥛 Латте, 🍵 Чай.

Переменная	Латте vs Эспрессо (OR)	Чай vs Эспрессо (OR)
Пол (женщина vs мужчина)	1.8	0.7
Возраст (за +1 год)	0.95	1.08
Экономический факультет vs IT	1.4	2.5
Гуманитарный факультет vs IT	2.2	1.6

- Как влияют предикторы на выбор напитка?

Какой кофе выберут студенты?

Мультиномиальная логистическая регрессия используется для предсказания выбора напитка: ☕ Эспрессо (базовая категория), 🥛 Латте, 🍵 Чай.

Переменная	Латте vs Эспрессо (OR)	Чай vs Эспрессо (OR)
Пол (женщина vs мужчина)	1.8	0.7
Возраст (за +1 год)	0.95	1.08
Экономический факультет vs IT	1.4	2.5
Гуманитарный факультет vs IT	2.2	1.6

- Можно ли, глядя на эти OR, однозначно сказать какой напиток выберет студент с определенными характеристиками?

Ответ: Нет. OR показывают только шансы относительно базового класса. Чтобы предсказать конкретный выбор, нужно считать вероятности всех альтернатив одновременно, а OR сами по себе не оценивают вероятность наступления события.

Какой кофе выберут студенты?

Мультиномиальная логистическая регрессия используется для предсказания выбора напитка: ☕ Эспрессо (базовая категория), 🥛 Латте, 🍵 Чай.

Переменная	Латте vs Эспрессо (OR)	Чай vs Эспрессо (OR)
Пол (женщина vs мужчина)	1.8	0.7
Возраст (за +1 год)	0.95	1.08
Экономический факультет vs IT	1.4	2.5
Гуманитарный факультет vs IT	2.2	1.6

- Если из модели убрать чай, изменятся ли OR для латте? А вероятность выбора студентом латте?

Ответ: OR для латте остаются такими же, потому что OR отражают отношение шансов выбрать латте к выбору базового класса (эспрессо). Но вероятности выбора латте увеличатся, так как вероятность перераспределится между оставшимися классами.

Какой кофе выберут студенты?

Мультиномиальная логистическая регрессия используется для предсказания выбора напитка: ☕ Эспрессо (базовая категория), 🥛 Латте, 🍵 Чай.

Переменная	Латте vs Эспрессо (OR)	Чай vs Эспрессо (OR)
Пол (женщина vs мужчина)	1.8	0.7
Возраст (за +1 год)	0.95	1.08
Экономический факультет vs IT	1.4	2.5
Гуманитарный факультет vs IT	2.2	1.6

- Можно ли на этих данных прямо оценить влияние пола на выбор латте или чая?

  Ответ: Нельзя напрямую сравнивать латте и чай, потому что OR дают отношение к базовому классу, а не между альтернативами.

Порядковая логистическая регрессия

Порядковая логистическая регрессия используется для моделирования целевой переменной, которая имеет упорядоченные категории. Например, уровень удовлетворенности клиентов, рейтинг качества продукта или степень согласия с утверждением. Категории должны обладать естественным порядком, но интервалы между ними не обязательно равны. В отличие от мультиномиальной логистической регрессии, которая моделирует вероятность каждого отдельного класса, порядковая логистическая регрессия оценивает кумулятивные вероятности, то есть вероятность того, что наблюдение попадает в данный класс или любой класс с меньшим порядковым значением. Позволят интерпретировать влияние предикторов на вероятность перехода между уровнями значений целевой переменной.

Допущение порядковой логистической регрессии

Модель предполагает пропорциональные шансы (proportional odds assumption): влияние каждого предиктора одинаково на каждом уровне целевой переменной. Нарушение допущения может привести к искажению интерпретации коэффициентов.

Фактически проверяется, что коэффициенты модели каждого предиктора одинаковы для всех категориальных границ. То есть влияние предиктора на вероятность перехода из любой категории в следующую постоянно.

Тест параллельных линий

Проверка допущения проводится с помощью теста параллельных линий (parallel lines test). Сравнивается модель с одинаковыми коэффициентами для всех уровней и модель с разными коэффициентами для разных уровней.

- если тест не значим → допущение proportional odds выполняется.
- если тест значим → коэффициенты различаются для разных границ категорий → допущение нарушено.

В случае нарушения допущения рекомендуется использовать мультиномиальную модель.

Тест параллельных линий

Зависимая переменная: удовлетворенность: низкая (1), средняя (2), высокая (3).

Независимые переменные: пол, возраст

Сравнение	OR (пол)	OR (возраст)
1 vs 2,3	2.01	1.05
1,2 vs 3	2.01	1.05

Отношения шансов одинаковы для обеих границ

Сравнение	OR (пол)	OR (возраст)
1 vs 2,3	1.22	1.01
1,2 vs 3	3.32	1.08

Логарифм шансов разный для разных границ → parallel lines assumption нарушается

Пример целевой переменной

Целевая переменная имеет следующие значения:

1 – нет образования
2 – среднее образование
3 – среднее специальное образование
4 – неоконченное высшее образование
5 – высшее образование
6 – послевузовское образование

Результатом предсказания является вероятность достижения каждого уровня образования, а также всех более низких уровней. Например, модель оценивает вероятность того, что человек имеет высшее образование или любой из нижележащих уровней образования.

Пример целевой переменной

Strongly Disagree	Disagree	Undecided	Agree	Strongly Agree
(1)	(2)	(3)	(4)	(5)

Рассмотрим формулы для расчёта шансов попадания в определённую группу на шкале Лайкерта.

- шансы попадания в 1-ю группу: вероятность ответа 1 деленная на сумму вероятностей всех остальных ответов = p1/p(2+3+4+5)
- шансы попадания во 2-ю группу: вероятность ответа 2 + ответа 1, деленная на вероятность всех остальных ответов = p(1+2) / p(3+4+5)
- шансы попадания в 3-ю группу: p(1+2+3) / p(4+5)
- шансы попадания в 4-ю группу: p(1+2+3+4) / p(5)

Интерпретация коэффициентов порядковой логистической регрессии

Коэффициент показывает влияние предиктора на шансы попасть в более высокую категорию. Если $\beta_k > 0$, то увеличение предиктора на единицу увеличивает шансы более высоких категорий и наоборот.

Зависимая переменная: уровень удовлетворенности: 1 = “Очень недоволен”, 2 = “Недоволен”, 3 = “Нейтрально”, 4 = “Доволен”, 5 = “Очень доволен”

Предиктор: доход.

β_income = 0.5 → OR = 1.65

Вывод: Увеличение дохода на единицу (например, +1000₽) увеличивает кумулятивные шансы на 65%. То есть, шансы, что человек, например, окажется в категории >3 по сравнению с ≤ 3, увеличиваются в 1.65 раза для каждого шага X.

Что влияет на удовлетворенность обучением в магистратуре?

Зависимая переменная: уровень удовлетворённости обучением
1 = очень низкий, 2 = низкий, 3 = средний, 4 = высокий, 5 = очень высокий

Предикторы:

- Учился в бакалавриате в том же университете (Да / Нет)
- Пол (женщина / мужчина)
- Возраст (в годах)
- Работает во время учебы (Да / Нет)

Предиктор	OR (для перехода на более высокий уровень)
Учился в бакалавриате в том же университете (Да vs Нет)	1.6
Пол (женщина vs мужчина)	1.3
Возраст (за +1 год)	1.05
Работает во время учебы (Да vs Нет)	0.8

Что влияет на удовлетворенность обучением в магистратуре?

- Студенты, которые учились в том же универе, имеют на 60% больше шансов быть в более высокой категории удовлетворённости.
- Женщины имеют на 30% больше шансов на более высокий уровень удовлетворённости, чем мужчины.
- С каждым годом шансы на более высокий уровень удовлетворённости увеличиваются на 5%.
- Те, кто работает, имеют на 20% меньше шансов на более высокий уровень удовлетворённости.

Предиктор	OR (для перехода на более высокий уровень)
Учился в бакалавриате в том же университете (Да vs Нет)	1.6
Пол (женщина vs мужчина)	1.3
Возраст (за +1 год)	1.05
Работает во время учебы (Да vs Нет)	0.8

Спасибо за внимание!